

**BENEMÉRITA UNIVERSIDAD AUTÓNOMA DE
PUEBLA**

FACULTAD DE INGENIERÍA QUÍMICA

Laboratorio de Termodinámica y Modelado Predictivo Molecular

MANUAL DIDÁCTICO DE FORMACIÓN PROGRESIVA

Predicción de Entalpías Estándar de Combustión Mediante Machine Learning

De las Leyes Termodinámicas Clásicas al Modelado Predictivo de Alto Rendimiento

Guía Integral de Aprendizaje, Ecuaciones, Código y Roadmap

Diseñado especialmente para la alumna:

KAROL PAOLA CAMACHO LÓPEZ

Estudiante de Ingeniería Química · FIQ BUAP

Enfoque Pedagógico:

Acompañamiento docente en Termodinámica Química, Ciencia de Datos y Machine Learning

Objetivo Central de Aprendizaje:

Desarrollar y validar un modelo autónomo de regresión supervisada para la predicción de entalpías estándar de combustión (ΔH_c°) a partir de descriptores moleculares y fisicoquímicos, fundamentado en la literatura termodinámica rigurosa.

Horizonte de Formación:

Fase Actual: Modelo Predictivo de Entalpías de Combustión (Septiembre – Noviembre 2026)

Meta Mayor: Transición al Modelado de Equilibrio Químico (10 de Diciembre de 2026)

Heroica Puebla de Zaragoza, México · Septiembre 2026

Tabla de Contenidos

Carta del Profesor a Karol Paola	2
1 Leyes Termodinámicas y Fenomenología de la Combustión	3
1.1 La Ley Cero: El Concepto Físico de Temperatura	3
1.1.1 Enunciado Físico y Sentido Experimental	3
1.2 La Primera Ley: Conservación de Energía y el Origen de la Entalpía	3
1.2.1 Energía Interna (U), Calor (Q) y Trabajo (W)	3
1.2.2 Deducción Matemática Rigurosa de la Entalpía ($H = U + PV$)	3
1.3 La Segunda Ley: Espontaneidad y la Energía Libre de Gibbs	5
1.3.1 Entropía (S) e Irreversibilidad	5
1.3.2 La Ecuación de Gibbs: $\Delta G^\circ = \Delta H^\circ - T\Delta S^\circ$	6
1.3.3 Conexión con el Equilibrio Químico (K_{eq})	6
1.4 Estequiometría de Combustión Completa y Ley de Hess	6
1.4.1 La Ecuación Estequiométrica General	6
1.4.2 Cálculo de Entalpía por la Ley de Hess	7
1.5 Calorimetría de Bomba de Mahler: El Origen Experimental de tus Datos	8
1.5.1 El Principio de Medición a Volumen Constante	8
1.5.2 Conversión de ΔU_c a ΔH_c°	8
1.6 ¿Por qué Requerimos Machine Learning en Lugar de Medir Todo?	8
2 Configuración del Laboratorio Digital: PyCharm, Entornos y Git	10
2.1 Estructura Estándar del Repositorio	10
2.2 Paso a Paso: Configurar el Entorno Virtual en PyCharm	11
2.3 Instalación de Dependencias desde la Terminal Integrada	11
2.4 Manejo Estricto de Rutas Relativas (Regla de Oro)	11
3 Norma de Estandarización y Trazabilidad Documental	12
3.1 Estructura Universal de Nombres de Archivo	12
3.1.1 Prefijos Oficiales de Fase (CÓDIGO_FASE)	12
3.1.2 Expresión Regular (Regex) de Validación	13
4 Librerías Científicas para Ingeniería Química: Guía Línea por Línea	14
4.1 NumPy: Arreglos Vectorizados de Alto Rendimiento	14
4.2 Pandas: La Tabla de Datos del Ingeniero Químico	14
4.3 ChemPy: Estequiometría y Balance Automatizado	15
5 Representación Molecular: De la Química a los Números	16
5.1 La Notación SMILES: Moléculas Escritas en Texto	16
5.2 Vector de Descriptores Moleculares y Físicoquímicos ($\mathbf{x}$)	16

6	Análisis Especializado del Trabajo Público del Dr. Arzola Flores	18
6.1	Ficha del Trabajo Público de Referencia	18
6.2	¿Cuál fue el Problema Científico que Abordaron?	18
6.3	El Dataset Utilizado y su Curaduría	18
6.4	¿Qué Crearon y Cómo lo Hicieron?	18
6.5	Resultados Cuantitativos Alcanzados en su Publicación	19
6.6	Lecciones Didácticas para Nuestro Propio Modelo	19
7	Machine Learning Fundamental: Algoritmos de Regresión Explicados	20
7.1	¿Qué es un Problema de Regresión Supervisada?	20
7.2	Regresión Lineal por Mínimos Cuadrados Ordinarios (OLS)	20
7.2.1	Ecuación del Modelo y Función de Costo (Loss)	20
7.2.2	Solución Analítica Matricial	20
7.3	Regularización: Evitando el Sobreajuste con Ridge y Lasso	21
7.3.1	El Dilema Sesgo-Varianza (<i>Bias-Variance Tradeoff</i>)	21
7.3.2	Regresión Ridge (Penalización L_2)	21
7.3.3	Regresión Lasso (Penalización L_1)	21
7.4	Árboles de Decisión y Random Forest Regressor	21
7.4.1	¿Cómo Funciona un Árbol de Regresión Individual?	21
7.4.2	Random Forest: El Poder del Ensamble	22
7.5	Pipeline Maestro de Scikit-Learn (Sin Data Leakage)	22
8	Validación Científica, Métricas y Diagnóstico de Residuales	24
8.1	Fórmulas Matemáticas de las Métricas de Error	24
8.2	El Diagnóstico Gráfico de Residuales ($e_i = y_i - \hat{y}_i$)	25
9	Plan de Trabajo: Metas del Viernes y Hoja de Ruta a Diciembre	26
9.1	Checklist Obligatoria para este Primer Viernes	26
9.2	Hoja de Ruta Maestra por Fases (Septiembre a Diciembre 2026)	27
9.3	El Hito Decisivo del 10 de Diciembre de 2026	27
10	Catálogo de Errores Frecuentes y Cómo Resolverlos	28

Carta del Profesor a Karol Paola

Estimada Karol Paola:

Bienvenida formalmente a este apasionante proyecto formativo en la Facultad de Ingeniería Química de nuestra universidad. Estás a punto de cruzar un puente fundamental para la ingeniería del siglo XXI: conectar los principios inmutables de la **Termodinámica Clásica** con la potencia predictiva del **Machine Learning**.

Sé muy bien que adentrarse en la inteligencia artificial y la ciencia de datos puede generar incertidumbre al principio. Hay una avalancha de términos nuevos: hiperparámetros, regresiones regularizadas, sobreajuste, matrices de dispersión, validación cruzada. Quiero que mantengas la calma y recuerdes siempre este principio pedagógico que guiará cada una de nuestras sesiones:

«El algoritmo es solo una calculadora avanzada de patrones estadísticos; la física y la química son las que dictan si el resultado tiene sentido o no.»

Tu meta en esta primera etapa no es construir sistemas difusos ni memorizar decenas de algoritmos que no aplican a nuestro caso. Tu objetivo es claro, nítido y medible: **diseñar, entrenar, auditar y validar tu propio modelo predictivo de entalpía estándar de combustión (ΔH_c°)**, comprendiendo cada dato, cada ecuación termodinámica y cada línea de código.

No necesitas aprender todo Python de golpe ni dominar enciclopedias de estadística para comenzar. Trabajaremos bajo la metodología de **Aprendizaje Just-in-Time (JIT)**:

1. Estudiarás la ley física exacta del fenómeno (¿por qué la combustión libera calor?, ¿cómo mide la bomba calorimétrica?, ¿cómo se expresa matemáticamente?).
2. Entenderás cómo traducir esa física a números que una computadora pueda procesar (masa molar, balance de oxígeno, conteo de heteroátomos).
3. Aprenderás el comando específico de la librería adecuada (**pandas**, **numpy**, **chempy**, **scikit-learn**).
4. Resolverás un ejercicio conceptual y lo aplicarás inmediatamente en tu propio cuaderno de trabajo.

Este manual ha sido redactado como si estuviéramos sentados en el cubículo revisando tus dudas paso a paso. Úsalo como tu guía de cabecera. Pregunta todo lo que no quede claro, ejecuta cada celda de código por ti misma y disfruta el proceso de convertirte en una ingeniera química con dominio real de la ciencia de datos.

Tu Profesor y Mentor de Proyecto
Laboratorio de Termodinámica y Modelado Molecular
Facultad de Ingeniería Química · BUAP

CAPÍTULO 1

Leyes Termodinámicas y Fenomenología de la Combustión

Karol Paola, antes de solicitarle a un algoritmo de Machine Learning que prediga un número, debemos entender qué significa físicamente ese número. En este capítulo desglosaremos cada ley fundamental, cada variable de estado y cada ecuación que rige la liberación de energía en forma de calor.

1.1 La Ley Cero: El Concepto Físico de Temperatura

1.1.1 Enunciado Físico y Sentido Experimental

Si dos sistemas termodinámicos A y B se encuentran individualmente en equilibrio térmico con un tercer sistema C (el termómetro calorimétrico), entonces los sistemas A y B están en equilibrio térmico entre sí:

$$(T_A = T_C) \wedge (T_B = T_C) \implies T_A = T_B \quad (1.1)$$

¿Por qué le importa esto a tu modelo predictivo? Porque en termoquímica todas las propiedades estándar se reportan a una temperatura de referencia idéntica: $T^\circ = 298.15 \text{ K}$ (25.00°C). Si comparáramos una entalpía de combustión medida a 25°C con otra medida a 100°C , el modelo aprendería un patrón falso, pues estaría mezclando la energía de reacción con el calor sensible ($C_p\Delta T$) de las sustancias.

1.2 La Primera Ley: Conservación de Energía y el Origen de la Entalpía

1.2.1 Energía Interna (U), Calor (Q) y Trabajo (W)

La Primera Ley postula que la energía del universo es constante: no se crea ni se destruye, solo se transforma. Para un sistema cerrado en reposo:

$$dU = \delta Q - \delta W \quad (1.2)$$

donde U es la **energía interna** (suma de la energía cinética traslacional, rotacional, vibracional y la energía potencial electrostática de los enlaces covalentes e interacciones intermoleculares).

El trabajo cuasiestático de expansión o compresión de volumen frente a una presión externa P se define como:

$$\delta W = P dV \implies dU = \delta Q - P dV \quad (1.3)$$

1.2.2 Deducción Matemática Rigurosa de la Entalpía ($H = U + PV$)

En la mayoría de los reactores industriales, mecheros y llamas abiertas, las reacciones químicas ocurren a **presión constante** (la presión atmosférica circundante, $P = \text{constante} \implies dP = 0$).

Si integramos la Primera Ley a presión constante:

$$\Delta U = Q_p - P \Delta V \implies Q_p = \Delta U + P \Delta V \quad (1.4)$$

Para evitar tener que calcular el cambio de volumen ΔV en cada reacción química, los termodinámicos definieron una nueva propiedad compuesta llamada **Entalpía** (H):

$$H \equiv U + PV \quad (1.5)$$

Diferenciando esta definición:

$$dH = dU + d(PV) = dU + P dV + V dP \quad (1.6)$$

Sustituyendo la Primera Ley ($dU = \delta Q - P dV$):

$$dH = (\delta Q - P dV) + P dV + V dP = \delta Q + V dP \quad (1.7)$$

Bajo condición **isobárica** ($dP = 0$):

$$dH = \delta Q_p \implies \Delta H = Q_p \quad (1.8)$$


Lección Clave del Profesor

La entalpía (ΔH) no es un concepto místico: es simplemente el **calor absorbido o liberado por una reacción química cuando se lleva a cabo a presión constante**.

- Si $\Delta H < 0$: El sistema libera calor hacia el entorno $\longrightarrow$ **Reacción Exotérmica** (Combustión).
- Si $\Delta H > 0$: El sistema absorbe calor del entorno $\longrightarrow$ **Reacción Endotérmica**.

Ejercicio Pedagógico: 1.1: Calor Isobárico vs Cambio de Energía Interna

Problema: Se quema 1 mol de metano gaseoso (CH_4) a $P = 1.0$ bar y $T = 298.15$ K según la reacción:



Experimentalmente se mide una variación de entalpía $\Delta H^\circ = -890.8$ kJ/mol. Calcula el calor intercambiado a presión constante (Q_p) y la variación de energía interna (ΔU°). Considera comportamiento de gas ideal para los gases y volumen despreciable para el agua líquida ($R = 8.314$ J/(mol · K)).

Solución Paso a Paso:

1. **Cálculo de Q_p :** Como la presión es constante, por definición directa:

$$Q_p = \Delta H^\circ = -890.8 \text{ kJ/mol}$$

2. **Cálculo del cambio de moles gaseosos (Δn_g):**

$$\Delta n_g = n_{\text{gases, productos}} - n_{\text{gases, reactivos}} = 1 \text{ mol } (CO_2) - [1 \text{ mol } (CH_4) + 2 \text{ mol } (O_2)] = -2$$

3. **Relación entre ΔH y ΔU :**

$$\Delta H = \Delta U + \Delta(PV) \approx \Delta U + \Delta n_g RT$$

$$\Delta U = \Delta H - \Delta n_g RT$$

4. **Sustitución numérica con cuidado de unidades:**

$$\Delta n_g RT = (-2 \text{ mol}) \cdot (8.314 \times 10^{-3} \text{ kJ/(mol} \cdot \text{K)}) \cdot (298.15 \text{ K}) = -4.958 \text{ kJ}$$

$$\Delta U = -890.8 \text{ kJ} - (-4.958 \text{ kJ}) = -885.84 \text{ kJ/mol}$$

Conclusión pedagógica: La energía liberada como calor a presión constante (-890.8 kJ) es mayor en magnitud que la variación de energía interna (-885.8 kJ) porque la atmósfera realizó un trabajo de compresión ($P\Delta V < 0$) sobre el sistema al reducirse el número de moles gaseosos.

1.3 La Segunda Ley: Espontaneidad y la Energía Libre de Gibbs

1.3.1 Entropía (S) e Irreversibilidad

La combustión completa de un hidrocarburo es un proceso macroscópicamente irreversible: jamás observamos que el dióxido de carbono y el agua líquida se recombinen espontáneamente a temperatura ambiente para regenerar gasolina y oxígeno molecular. La Segunda Ley establece que en cualquier proceso espontáneo en un sistema aislado, la entropía total del universo aumenta:

$$\Delta S_{\text{universo}} = \Delta S_{\text{sistema}} + \Delta S_{\text{alrededores}} > 0 \quad (1.9)$$

1.3.2 La Ecuación de Gibbs: $\Delta G^\circ = \Delta H^\circ - T\Delta S^\circ$

Para un sistema cerrado a temperatura y presión constantes, el calor cedido a los alrededores es $-\Delta H_{\text{sistema}}$, por lo que $\Delta S_{\text{alrededores}} = -\frac{\Delta H_{\text{sistema}}}{T}$. Sustituyendo:

$$\Delta S_{\text{universo}} = \Delta S_{\text{sistema}} - \frac{\Delta H_{\text{sistema}}}{T} > 0 \quad (1.10)$$

Multiplicando por $-T$:

$$-T\Delta S_{\text{universo}} = \Delta H_{\text{sistema}} - T\Delta S_{\text{sistema}} < 0 \quad (1.11)$$

Se define la **Energía Libre de Gibbs** (G) como:

$$G \equiv H - TS \implies \Delta G^\circ = \Delta H^\circ - T\Delta S^\circ \quad (1.12)$$

Un proceso es termodinámicamente espontáneo a T y P constantes si y solo si $\Delta G < 0$. Como las reacciones de combustión liberan una cantidad inmensa de calor ($\Delta H_c^\circ \ll 0$), el término entálpico domina abrumadoramente, haciendo que ΔG_c° sea intensamente negativo (≈ -800 a -10000 kJ/mol).

1.3.3 Conexión con el Equilibrio Químico (K_{eq})

En la Fase final de tu formación (hacia el 10 de diciembre de 2026), relacionarás la energía libre con la constante de equilibrio químico mediante la ecuación de van 't Hoff:


$$\Delta G^\circ = -RT \ln K_{eq} \implies K_{eq} = \exp\left(-\frac{\Delta G^\circ}{RT}\right) \quad (1.13)$$

Al ser ΔG_c° enormemente negativo, $K_{eq} \gg 10^{50}$, lo que demuestra termodinámicamente que la combustión procede al 100% hasta agotar el reactivo limitante.

1.4 Estequiometría de Combustión Completa y Ley de Hess

1.4.1 La Ecuación Estequiométrica General

Para cualquier molécula orgánica neutra formada por carbono, hidrógeno, oxígeno y nitrógeno con fórmula molecular $C_aH_bO_cN_d$:



Realizando el balance de materia elemental para el oxígeno:

$$c + 2\nu_{O_2} = 2a + \frac{b}{2} \implies \nu_{O_2} = a + \frac{b}{4} - \frac{c}{2} \quad (1.15)$$

¡Regla de Oro en Termodinámica de Combustión!

En las convenciones del NIST y la IUPAC a 298.15 K, el agua resultante de la combustión estándar se define en **estado líquido** ($H_2O_{(l)}$). Esto corresponde al **Poder Calorífico Superior (PCS)**. En calderas industriales se suele considerar agua vapor ($H_2O_{(g)}$, Poder Calorífico Inferior, PCI). Para el modelo de Machine Learning, entrenaremos siempre con el estándar científico internacional: **agua líquida**.

1.4.2 Cálculo de Entalpía por la Ley de Hess

La entalpía es una **función de estado**: su cambio neto depende únicamente del estado inicial y del estado final, no de la trayectoria seguida. Por tanto:

$$\Delta H_c^\circ = \sum \nu_{\text{prod}} \Delta H_{f,\text{prod}}^\circ - \sum \nu_{\text{react}} \Delta H_{f,\text{react}}^\circ \quad (1.16)$$

Para la combustión de $C_a H_b O_c N_d$:

$$\Delta H_c^\circ = a \Delta H_f^\circ(CO_{2(g)}) + \frac{b}{2} \Delta H_f^\circ(H_2O_{(l)}) + \frac{d}{2} \Delta H_f^\circ(N_{2(g)}) - \Delta H_f^\circ(\text{molécula}) - \nu_{O_2} \Delta H_f^\circ(O_{2(g)}) \quad (1.17)$$

Recordando que por convención termodinámica ΔH_f° de los elementos puros en su forma más estable es cero ($\Delta H_f^\circ(O_{2(g)}) = 0$, $\Delta H_f^\circ(N_{2(g)}) = 0$):

$$\Delta H_c^\circ = a(-393.51 \text{ kJ/mol}) + \frac{b}{2}(-285.83 \text{ kJ/mol}) - \Delta H_f^\circ(\text{molécula}) \quad (1.18)$$

Ejercicio Pedagógico: 1.2: Balance y Cálculo de Entalpía por Ley de Hess

Problema: La entalpía estándar de formación del etanol líquido ($C_2H_5OH_{(l)}$) a 298.15 K es $\Delta H_f^\circ = -277.69 \text{ kJ/mol}$.


1. Escribe y balancea la reacción de combustión completa.
2. Calcula teóricamente su entalpía estándar de combustión (ΔH_c°).
3. Calcula la entalpía específica liberada por gramo de etanol ($M = 46.07 \text{ g/mol}$).

Solución Paso a Paso:

1. **Fórmula molecular del etanol:** $C_2H_6O_1 \implies a = 2, b = 6, c = 1, d = 0$.

$$\nu_{O_2} = a + \frac{b}{4} - \frac{c}{2} = 2 + \frac{6}{4} - \frac{1}{2} = 2 + 1.5 - 0.5 = 3$$

Reacción balanceada:



2. **Aplicación de la Ley de Hess:**

$$\Delta H_c^\circ = 2 \cdot (-393.51) + 3 \cdot (-285.83) - (-277.69)$$

$$\Delta H_c^\circ = -787.02 - 857.49 + 277.69 = -1366.82 \text{ kJ/mol}$$

3. **Entalpía específica (Poder calorífico por gramo):**

$$\Delta h_c^\circ = \frac{\Delta H_c^\circ}{M} = \frac{-1366.82 \text{ kJ/mol}}{46.07 \text{ g/mol}} = -29.67 \text{ kJ/g}$$

1.5 Calorimetría de Bomba de Mahler: El Origen Experimental de tus Datos

La enorme mayoría de los datos tabulares que procesarás provienen históricamente de un **calorímetro de bomba de Mahler**:

1.5.1 El Principio de Medición a Volumen Constante

La bomba calorimétrica es un recipiente de acero inoxidable de paredes gruesas sumergido en una masa conocida de agua. Como la bomba está sellada herméticamente:

$$dV = 0 \implies W = \int P dV = 0 \quad (1.19)$$

Por la Primera Ley ($dU = \delta Q - \delta W$):

$$\Delta U_c = Q_v \quad (1.20)$$

El calor desprendido eleva la temperatura del agua y de los componentes del calorímetro:

$$Q_v = -C_{\text{calorímetro}} \cdot \Delta T_{\text{corregido}} \quad (1.21)$$

donde $C_{\text{calorímetro}}$ (la capacidad calorífica efectiva o equivalente en agua del equipo) se calibra previamente quemando pastillas de ácido benzoico patrón de alta pureza ($\Delta_c u = -26434$ J/g).

1.5.2 Conversión de ΔU_c a ΔH_c°

Como la bomba mide ΔU_c y no ΔH_c , se aplica la corrección termodinámica:

$$\Delta H_c^\circ = \Delta U_c + \Delta n_g RT + \Delta H_{\text{Washburn}} \quad (1.22)$$

donde $\Delta H_{\text{Washburn}}$ agrupa las correcciones por:

- La no idealidad de los gases reales a 30 bar de presión de oxígeno inicial.
- La energía liberada por el alambre de ignición de platino o níquel-cromo.
- El calor de formación y disolución de trazas de ácido nítrico (HNO_3) formado por nitrógeno atmosférico residual.

1.6 ¿Por qué Requerimos Machine Learning en Lugar de Medir Todo?

Podrías preguntarte: si la bomba calorimétrica es tan exacta, ¿por qué no medimos experimentalmente todas las moléculas y nos olvidamos del Machine Learning?

1. **Demanda de Masa:** Un calorímetro de bomba requiere entre 0.5 g y 1.0 g de sustancia pura. La síntesis orgánica preliminar de fármacos o catalizadores novedosos rinde con frecuencia menos de 10 mg.
2. **Costo y Tiempo:** Una sola corrida calorimétrica rigurosa con calibración, repeticiones y correcciones de Washburn toma de 2 a 4 días de trabajo intensivo de laboratorio.

3. **Seguridad Operativa:** Compuestos altamente reactivos, peróxidos, nitratos inestables o sustancias químicas tóxicas no pueden someterse a combustión a 30 bar sin riesgo de daño estructural o peligro para el experimentador.

CAPÍTULO 2

Configuración del Laboratorio Digital: PyCharm, Entornos y Git

Karol Paola, antes de escribir una sola línea de código químico, debemos asegurar que tu espacio digital sea reproducible, ordenado y profesional. Un modelo científico no sirve si solo funciona en una computadora específica.

2.1 Estructura Estándar del Repositorio

Abre tu explorador de archivos y confirma que la carpeta raíz del proyecto contenga exactamente la siguiente arquitectura de directorios:

Estructura Estandarizada del Proyecto

```
Modelo Entalpias de Combustion/
|-- data/
|   |-- raw/                <-- Datos originales intactos (solo lectura)
|   |   '-- base_entalpias.csv
|   '-- processed/          <-- Tablas limpias con variables calculadas
|-- notebooks/
|   |-- 01_exploracion_inicial.ipynb <-- Tu cuaderno del primer viernes
|   '-- 02_limpieza_y_eda.ipynb
|-- src/                    <-- Modulos Python reutilizables (.py)
|   |-- __init__.py
|   '-- funciones_quimicas.py <-- Balance de materia y utilidades
|-- config/                 <-- Configuraciones del proyecto
|   |-- matriz_actividades.json
|   '-- MATRIZ_ACTIVIDADES.md
|-- reportes/               <-- Documentos tecnicos y este manual en LaTeX
|   '-- MANUAL_MAESTRO_PREPARACION.tex
|-- .gitignore              <-- Archivos excluidos de Git (.venv, cache)
|-- README.md               <-- Descripcion oficial del repositorio
|-- KANBAN.md               <-- Tablero de actividades sincronizado
|-- ROADMAP.md              <-- Diagrama cronologico de entrega
'-- requirements.txt         <-- Lista formal de dependencias y versiones
```

2.2 Paso a Paso: Configurar el Entorno Virtual en PyCharm

Protocolo 2.1: Entorno Virtual Aislado (.venv)

1. **Abrir la Carpeta:** Inicia PyCharm, selecciona **Open** y abre la carpeta **Modelo Entalpías de Combustion**.
2. **Configurar Intérprete:** Ve a **File** → **Settings** (en Linux/Windows) o **PyCharm** → **Preferences** (en macOS).
3. Despliega **Project: Modelo Entalpías...** y haz clic en **Python Interpreter**.
4. Haz clic en **Add Interpreter** → **Add Local Interpreter...**
5. Selecciona **Virtualenv Environment** → **New Environment**.
6. Verifica que la carpeta de destino termine en **.venv** y que el intérprete base sea Python 3.10 o superior. Haz clic en **OK**.

2.3 Instalación de Dependencias desde la Terminal Integrada

Abre la pestaña **Terminal** en la parte inferior de PyCharm. Asegúrate de que el cursor comience con **(.venv)**. Ejecuta exactamente:

```
1 # 1. Actualizar el instalador de paquetes pip
2 pip install --upgrade pip
3
4 # 2. Instalar el nucleo interactivo para cuadernos Jupyter
5 pip install jupyter jupyterlab ipykernel
6
7 # 3. Instalar la suite cientifica de calculo y Machine Learning
8 pip install numpy pandas chempy matplotlib seaborn scikit-learn
```

2.4 Manejo Estricto de Rutas Relativas (Regla de Oro)

Jamás escribas rutas absolutas con letras de disco o carpetas personales como: `pd.read_csv("C:/Users/Karol/Docu`. Si lo haces, el código fallará inmediatamente cuando se ejecute en la computadora del profesor.

Utiliza siempre `os.path.join()` o `pathlib.Path` basándote en la raíz del proyecto:

```
1 import os
2 import pandas as pd
3
4 # Construir la ruta relativa desde la carpeta notebooks/ hacia data/raw/
5 ruta_datos = os.path.join("../", "data", "raw", "base_entalpías.csv")
6 df = pd.read_csv(ruta_datos)
7 print(f"Dimensiones del dataset cargado: {df.shape[0]} filas, {df.shape[1]}
      columnas.")
```

CAPÍTULO 3

Norma de Estandarización y Trazabilidad Documental

Karol Paola, para que tu flujo de trabajo sea riguroso y para que las automatizaciones del proyecto reconozcan tus avances de forma determinista, cada entregable producido debe satisfacer la siguiente norma universal de nomenclatura.

3.1 Estructura Universal de Nombres de Archivo

[CÓDIGO_FASE]_[ID_ACTIVIDAD]_[TIPO]_[DESCRIPTOR]_[VERSION]_[ESTADO].[ext]

Bloque	Campo	Formato / Valores	Función Técnica en el Sistema
1	[CÓDIGO_FASE]	Prefijo de etapa (ej. F0-ENV, F1-DAT)	Ubica el entregable en la fase cronológica del Roadmap.
2	[ID_ACTIVIDAD]	3 letras + 2 dígitos (ej. ACT01, SIM01)	Identificador unívoco vinculado a la tarjeta Kanban.
3	[TIPO]	3 letras mayúsculas (DAT, SCR, NBK, REP)	Clasifica la naturaleza técnica del archivo.
4	[DESCRIPTOR]	Texto en minúsculas en snake_case	Síntesis temática del entregable (máximo 4 palabras).
5	[VERSION]	vX.Y (v0.1, v1.0, v2.0)	Versionado semántico (X: mayor; Y: menor).
6	[ESTADO]	DRAFT, REV, FINAL	Determina si el archivo es borrador, revisión o cierre.
Ext	[ext]	Extensión (.py, .ipynb, .csv, .pdf)	Formato nativo del software utilizado.

Tabla 3.1: Parámetros normativos de nomenclatura estricta.

3.1.1 Prefijos Oficiales de Fase (CÓDIGO_FASE)

- **F0-ENV (Entorno y Setup):** Infraestructura local, Git, entorno virtual .venv y ChemPy.
- **F1-DAT (Datos y Curaduría):** Adquisición de la base de datos de entalpías y depuración de duplicados.
- **F2-EDA (Exploración y Descriptores):** Análisis exploratorio de datos (EDA) y cálculo de variables moleculares.
- **F3-MLB (Machine Learning Base):** Ajuste de modelos lineales (OLS, Ridge) y Random Forest.

- **F4-VAL (Validación y Residuales):** Validación cruzada k -fold y diagnóstico de gráficos residuales.
- **F5-REP (Benchmarking de Literatura):** Comparación cuantitativa del modelo contra estándares reportados.
- **F6-SIM (Simulación de Procesos):** Balance termodinámico de combustión completa en DWSIM (.dwsim).
- **F7-EQK (Transición al Equilibrio):** Cálculo de energía de Gibbs y constantes de equilibrio $K_{eq}(T)$ para diciembre.

3.1.2 Expresión Regular (Regex) de Validación

Para que el motor de automatización valide formalmente un entregable antes de cerrar una tarea, el nombre de archivo debe coincidir con la siguiente regla lógica:

```
1 ^([0-7]-[A-Z]{3})_([A-Z]{3}\d{2})_([A-Z]{3})_([a-z0-9_]+)_(\d+\.\d+)_ (DRAFT|REV|
  FINAL)\.([a-zA-Z0-9_]+)$
```

CAPÍTULO 4

Librerías Científicas para Ingeniería Química: Guía Línea por Línea

En este capítulo analizaremos las herramientas computacionales que utilizarás en tu día a día: NumPy, Pandas, ChemPy, Scikit-Learn y Matplotlib/Seaborn.

4.1 NumPy: Arreglos Vectorizados de Alto Rendimiento

NumPy implementa arreglos homogéneos contiguos en memoria C (`ndarray`). Permite procesar millones de cálculos químicos sin recurrir a bucles `for` en Python.

```
1 import numpy as np
2
3 # 1. Definir arreglos vectorizados de entalpias molares (kJ/mol) y masas (g/mol)
4 entalpias_molares = np.array([-890.8, -1560.7, -2220.0, -2877.6]) # Metano, Etano,
   Propano, Butano
5 masas_molares = np.array([16.04, 30.07, 44.10, 58.12])
6
7 # 2. Operacion vectorizada directa: calculo de poder calorifico especifico (kJ/g)
8 entalpias_especificas = entalpias_molares / masas_molares
9 print("Entalpias especificas (kJ/g):", np.round(entalpias_especificas, 2))
10
11 # 3. Estadistica basica sobre el target
12 media_dH = np.mean(entalpias_molares)
13 desv_std = np.std(entalpias_molares)
14 print(f"Promedio: {media_dH:.2f} kJ/mol | Desv. Estandar: {desv_std:.2f} kJ/mol")
15
16 # 4. Mascara booleana para filtrar valores extremos
17 mascara_alta_energia = entalpias_molares < -2000.0
18 print("Compuestos con dH < -2000 kJ/mol:", entalpias_molares[mascara_alta_energia])
```

4.2 Pandas: La Tabla de Datos del Ingeniero Químico

Un `DataFrame` es una tabla interactiva en memoria donde las columnas son variables fisicoquímicas (*features*) y las filas son moléculas individuales.

```
1 import pandas as pd
2
3 # 1. Cargar la base de datos cruda
4 df = pd.read_csv('../data/raw/base_entalpias.csv')
5
6 # 2. Inspeccion inicial de dimensiones y tipos de columnas
7 print("Forma del dataset:", df.shape) # (num_filas, num_columnas)
8 print("\nTipos de datos y conteo de nulos:")
9 df.info()
10
```



```
11 # 3. Resumen estadístico de variables numéricas (media, std, min, percentiles, max)
12 display(df.describe())
13
14 # 4. Auditoria y remoción de valores nulos (NaN)
15 # REGLA DOCENTE: El target JAMAS se inventa ni se rellena con promedios. Si falta
    dH, se descarta la fila.
16 num_nulos_target = df['dH_combustion'].isnull().sum()
17 print(f"Filas con entalpia nula: {num_nulos_target}")
18 df_limpio = df.dropna(subset=['dH_combustion']).copy()
19
20 # 5. Detección y remoción de duplicados moleculares basados en SMILES
21 df_limpio = df_limpio.drop_duplicates(subset=['SMILES'])
22
23 # 6. Ingeniería de Variables (Feature Engineering): creación de nuevas columnas
    útiles
24 df_limpio['ratio_C_H'] = df_limpio['num_C'] / df_limpio['num_H']
```

4.3 ChemPy: Estequiometría y Balance Automatizado

ChemPy es una librería especializada de química computacional que permite extraer masas molares y balancear sistemas estequiométricos mediante álgebra lineal elemental.

```
1 from chempy import Substance
2 from chempy.chemistry import balance_stoichiometry
3
4 # 1. Instanciar una molecula a partir de su formula quimica
5 tolueno = Substance.from_formula('C7H8')
6 print(f"Masa molar del tolueno: {tolueno.mass:.3f} g/mol")
7 print("Composicion elemental (numero atomico: conteo):", tolueno.composition)
8 # Salida: {6: 7, 1: 8} -> 7 atomos de Carbono (Z=6) y 8 atomos de Hidrogeno (Z=1)
9
10 # 2. Balancear automaticamente la reaccion de combustion completa con O2
11 reactivos = {'C7H8', 'O2'}
12 productos = {'CO2', 'H2O'}
13
14 reac_bal, prod_bal = balance_stoichiometry(reactivos, productos)
15 print("\nReaccion de combustion del tolueno balanceada:")
16 print(f"{dict(reac_bal)} --> {dict(prod_bal)}")
17 # Salida esperada: {'C7H8': 1, 'O2': 9} --> {'CO2': 7, 'H2O': 4}
```

CAPÍTULO 5

Representación Molecular: De la Química a los Números

Karol Paola, un algoritmo de Machine Learning no entiende de geometrías moleculares tridimensionales ni de resonancia electrónica; únicamente procesa matrices numéricas $\mathbf{X} \in \mathbb{R}^{n \times p}$. En este capítulo aprenderás cómo convertir una molécula orgánica en un vector de números con significado termodinámico.

5.1 La Notación SMILES: Moléculas Escritas en Texto

El estándar mundial para almacenar moléculas en bases de datos es el formato **SMILES** (*Simplified Molecular Input Line Entry System*):

- **Átomos alifáticos:** Letras mayúsculas según la tabla periódica (C, N, O, S, F, Cl, Br, I). Los hidrógenos se asumen implícitos para satisfacer la valencia del átomo.
- **Aromaticidad:** Se indica con letras minúsculas. Por ejemplo, el benceno es c1ccccc1.
- **Tipos de enlace:** Enlace simple implícito; enlace doble con = (ej. etileno C=C); enlace triple con # (ej. acetileno C#C).
- **Ramificaciones:** Se colocan entre paréntesis justo después del átomo al que van enlazadas. Por ejemplo, el isobutano (2-metilpropano) se escribe CC(C)C.

5.2 Vector de Descriptores Moleculares y Fisicoquímicos (x)

Para alimentar nuestro modelo de regresión, cada compuesto i se representará como un vector fila:

$$\mathbf{x}_i = [M_i \quad n_{C,i} \quad n_{H,i} \quad n_{O,i} \quad n_{N,i} \quad \nu_{O_2,i} \quad \text{Ratio}_{C/H,i} \quad \text{EnlacesRotables}_i \quad \text{TPSA}_i] \quad (5.1)$$

Justificación termodinámica de cada descriptor:

1. **Masa Molar (M):** Correlaciona directamente con el tamaño molecular y la cantidad total de electrones y núcleos presentes.
2. **Conteo de Carbonos (n_C):** Cada carbono se oxida a CO_2 , liberando aproximadamente -393.5 kJ/mol. Es el principal predictor positivo de la magnitud de la entalpía.
3. **Conteo de Hidrógenos (n_H):** Cada dos hidrógenos forman un mol de $H_2O_{(l)}$, liberando -285.8 kJ/mol.
4. **Conteo de Oxígenos (n_O):** Los oxígenos presentes en la molécula ya están enlazados parcialmente al carbono o hidrógeno; por tanto, reducen la cantidad de oxígeno externo que se debe consumir y disminuyen la energía neta liberada en la combustión.

5. **Demanda Estequiométrica de Oxígeno** ($\nu_{O_2} = a + b/4 - c/2$): Sintetiza en una sola variable físico-química el potencial redox global de la molécula.

Ejercicio Pedagógico: 5.1: Construcción de un Vector de Descriptores

Problema: Para las siguientes tres moléculas:

- Molécula A: Metanol (CO , fórmula CH_4O)
- Molécula B: Acetona ($CC(=O)C$, fórmula C_3H_6O)
- Molécula C: Ácido acético ($CC(=O)O$, fórmula $C_2H_4O_2$)

Calcula manualmente su masa molar (M), su conteo atómico (n_C, n_H, n_O), su demanda estequiométrica de oxígeno (ν_{O_2}) y su razón C/H .

Solución:

Compuesto	Masa Molar (M)	n_C	n_H	n_O	$\nu_{O_2} = n_C + \frac{n_H}{4} - \frac{n_O}{2}$	Ratio C/H
Metanol (CH_4O)	32.04 g/mol	1	4	1	$1 + 1 - 0.5 = 1.5$	0.25
Acetona (C_3H_6O)	58.08 g/mol	3	6	1	$3 + 1.5 - 0.5 = 4.0$	0.50
Ácido Acético ($C_2H_4O_2$)	60.05 g/mol	2	4	2	$2 + 1 - 1.0 = 2.0$	0.50

Interpretación: Observa cómo la acetona requiere más oxígeno ($\nu_{O_2} = 4.0$) que el ácido acético ($\nu_{O_2} = 2.0$), a pesar de tener una masa molar casi idéntica. Como consecuencia, la entalpía de combustión de la acetona (≈ -1790 kJ/mol) es más del doble de exotérmica que la del ácido acético (≈ -874 kJ/mol). ¡La variable ν_{O_2} contiene enorme poder predictivo!

CAPÍTULO 6

Análisis Especializado del Trabajo Público del Dr. Arzola Flores

Karol Paola, en este capítulo dedicamos una sección específica y detallada a analizar con rigor científico la investigación pública desarrollada por el Dr. Jesús Andrés Arzola Flores y su grupo de colaboradores en la BUAP sobre la predicción de entalpías de combustión. Nuestro único y exclusivo objetivo pedagógico es aprender de su arquitectura y resultados para diseñar nuestro propio modelo predictivo limpio, transparente y autónomo.

6.1 Ficha del Trabajo Público de Referencia

- **Cita Científica Formal:** Saviñón-Flores, M. F., Arzola-Flores, J. A., García-Castro, M. A., Díaz-Sánchez, F., Vidal-Robles, E., & Maruri-Valderrabano, F. A. (2025). *Prediction of Standard Combustion Enthalpy of Organic Compounds Combining Machine Learning and Chemical Graph Theory: A Strategy*. **ACS Omega**, 10(36), 41828–41848.
- **Identificador DOI Oficial:** <https://doi.org/10.1021/acsomega.5c05927>

6.2 ¿Cuál fue el Problema Científico que Abordaron?

El objetivo del grupo consistió en predecir de manera generalizada y precisa la entalpía estándar de combustión (ΔH_c°) de una gran biblioteca de moléculas orgánicas con alta diversidad estructural (hidrocarburos lineales, ramificados, ciclos alifáticos, aromáticos, heterociclos oxigenados y nitrogenados). Buscaban una alternativa cuantitativa a la experimentación destructiva en calorímetros de bomba, útil para evaluar rápidamente el potencial energético de nuevos compuestos y biocombustibles.

6.3 El Dataset Utilizado y su Curaduría

- **Tamaño Muestral:** 3,477 compuestos orgánicos curados.
- **Fuentes de Datos:** Bases de datos termodinámicas de referencia internacional (NIST Chemistry WebBook, compilaciones termoquímicas calorimétricas históricas y reportes certificados).
- **Variable Objetivo (y):** Entalpía estándar de combustión a 298.15 K en kJ/mol (con valores que abarcan desde moléculas pequeñas como el metano hasta hidrocarburos complejos de más de 30 carbonos, con entalpías entre -800 y $-16,000$ kJ/mol).

6.4 ¿Qué Crearon y Cómo lo Hicieron?

El pipeline desarrollado por el grupo de investigación constó de las siguientes etapas secuenciales:

1. **Normalización de Identificadores:** Extracción y estandarización de cadenas SMILES canónicas para evitar representaciones redundantes de la misma estructura química.
2. **Generación de la Matriz de Diseño (X):** Extracción computacional de variables numéricas para cada una de las 3,477 moléculas.
3. **Partición de Datos:** División del conjunto total en un 80% de datos para entrenamiento (*Training Set*) y un 20% reservado estrictamente para prueba (*Test Set*), asegurando reproducibilidad mediante semillas fijas.
4. **Selección y Entrenamiento del Algoritmo Ganador:** Tras evaluar diversos estimadores (regresiones lineales y algoritmos de ensamble), el modelo que obtuvo el rendimiento más consistente y robusto fue un ensamble de árboles de decisión: **Random Forest Regressor**.
5. **Afinamiento de Hiperparámetros:** Control riguroso del número de árboles (`n_estimators`) y de la profundidad máxima (`max_depth`) para mitigar el riesgo de sobreajuste (*overfitting*).

6.5 Resultados Cuantitativos Alcanzados en su Publicación

En el conjunto de prueba independiente (*Test Set*), el modelo del Dr. Arzola Flores y colaboradores reportó los siguientes valores de referencia:

Métricas Oficiales Reportadas en ACS Omega 2025

$$R^2 \approx \mathbf{0.9810} \quad (\text{Coeficiente de determinación})$$

$$\text{MAE} \approx \mathbf{287.5988} \text{ kJ/mol} \quad (\text{Error Absoluto Medio})$$

6.6 Lecciones Didácticas para Nuestro Propio Modelo

Analizar este trabajo nos deja lecciones invaluables para nuestro proyecto:

1. **Random Forest es el Estimador Ideal para este Target:** La relación entre la estructura molecular y la entalpía de combustión presenta no-linealidades inherentes (tensión de anillo en ciclos pequeños, efectos de resonancia aromática, interacciones estéricas). Los ensambles de árboles capturan estas particiones no lineales sin sufrir por problemas de escala.
2. **La Métrica de Éxito es el MAE, no solo el R^2 :** Como la base de datos cubre un rango numérico gigantesco (de -890 a -16000 kJ/mol), la varianza total es inmensa. Un $R^2 = 0.98$ puede sonar casi perfecto, pero un MAE de 287 kJ/mol representa el margen real de incertidumbre media del modelo.
3. **Nuestro Camino Autónomo:** En lugar de complicarnos en esta etapa inicial con índices de grafos topológicos que aún no dominas, utilizaremos descriptores constitutivos, estequiométricos y fisicoquímicos directos (masa molar, balance de oxígeno, conteo de heteroátomos y enlaces). Diseñaremos nuestro propio pipeline claro, modular y 100% comprensible para ti.

CAPÍTULO 7

Machine Learning Fundamental: Algoritmos de Regresión Explicados

Karol Paola, en este capítulo aprenderás qué hace internamente cada algoritmo de regresión, deduciendo sus ecuaciones y entendiendo por qué los árboles y ensambles son tan efectivos.

7.1 ¿Qué es un Problema de Regresión Supervisada?

Disponemos de un conjunto de entrenamiento de n moléculas:

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\} \quad (7.1)$$

donde $\mathbf{x}_i \in \mathbb{R}^p$ es el vector de variables moleculares y $y_i \in \mathbb{R}$ es la entalpía de combustión medida experimentalmente. Nuestro objetivo es aprender una función hipótesis $\hat{y} = f(\mathbf{x})$ tal que el error entre las predicciones $\hat{y}$ y los valores reales y sea mínimo en moléculas nuevas que el modelo jamás haya visto.

7.2 Regresión Lineal por Mínimos Cuadrados Ordinarios (OLS)

7.2.1 Ecuación del Modelo y Función de Costo (Loss)

El modelo lineal asume que la entalpía predicha es una combinación lineal de las variables:

$$\hat{y}_i = w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_p x_{ip} = \mathbf{w}^T \mathbf{x}_i + b \quad (7.2)$$

Para encontrar los pesos óptimos $\mathbf{w}$, definimos la función de pérdida del **Error Cuadrático Medio (MSE)**:

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \left(y_i - (\mathbf{w}^T \mathbf{x}_i + b) \right)^2 \quad (7.3)$$

7.2.2 Solución Analítica Matricial

Expresando el sistema en notación matricial (añadiendo una columna de unos para el sesgo b en la matriz $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$):

$$L(\mathbf{w}) = \frac{1}{n} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 = \frac{1}{n} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) \quad (7.4)$$

Derivando con respecto al vector de pesos $\mathbf{w}$ e igualando a cero:

$$\nabla_{\mathbf{w}} L = -\frac{2}{n} \mathbf{X}^T (\mathbf{y} - \mathbf{X}\mathbf{w}) = \mathbf{0} \implies \mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y} \quad (7.5)$$

Si la matriz $\mathbf{X}^T \mathbf{X}$ es invertible, la solución analítica exacta es:

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (7.6)$$

7.3 Regularización: Evitando el Sobreajuste con Ridge y Lasso

7.3.1 El Dilema Sesgo-Varianza (*Bias-Variance Tradeoff*)

- **Subajuste (*Underfitting* / Alto Sesgo):** El modelo es demasiado simple (ej. asumir una línea recta cuando la relación es curva). Comete grandes errores tanto en entrenamiento como en prueba.
- **Sobreajuste (*Overfitting* / Alta Varianza):** El modelo memoriza el ruido del entrenamiento. Tiene un error casi nulo en Train, pero falla estrepitosamente en Test.

7.3.2 Regresión Ridge (Penalización L_2)

Ridge añade a la función de pérdida una penalización cuadrática proporcional a la magnitud de los pesos:

$$L_{\text{Ridge}}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \sum_{j=1}^p w_j^2 = \text{MSE} + \alpha \|\mathbf{w}\|_2^2 \quad (7.7)$$

donde $\alpha > 0$ es el hiperparámetro de regularización. **Efecto pedagógico:** Impide que ningún peso se vuelva astronómicamente grande, encogiéndolos hacia cero y aumentando la estabilidad del modelo.

7.3.3 Regresión Lasso (Penalización L_1)

Lasso penaliza el valor absoluto de los pesos:

$$L_{\text{Lasso}}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \sum_{j=1}^p |w_j| = \text{MSE} + \alpha \|\mathbf{w}\|_1 \quad (7.8)$$

Efecto pedagógico: Debido a la geometría de las esquinas de la norma L_1 , Lasso anula por completo los pesos de variables irrelevantes ($w_j = 0$), actuando como un seleccionador automático de variables químicas.

7.4 Árboles de Decisión y Random Forest Regressor

7.4.1 ¿Cómo Funciona un Árbol de Regresión Individual?

Un árbol de decisión particiona el espacio de descriptores en regiones rectangulares hiperdimensionales $R_1, R_2, \dots, R_M$. Para cualquier molécula que caiga en la región R_m , la predicción es simplemente el promedio de las entalpías de las moléculas de entrenamiento de esa región:

$$\hat{y}_{R_m} = \frac{1}{N_m} \sum_{i \in R_m} y_i \quad (7.9)$$

En cada nodo, el algoritmo elige la variable j y el punto de corte s que maximizan la reducción de varianza (disminución del MSE).

7.4.2 Random Forest: El Poder del Ensamble

Un solo árbol de decisión profundo tiende a sobreajustar con facilidad. **Random Forest** resuelve esto promediando las predicciones de B árboles descorrelacionados (típicamente $B = 100$ a 300):

$$\hat{y}_{\text{RF}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (7.10)$$

Para asegurar que los árboles sean distintos entre sí, utiliza dos mecanismos aleatorios:

1. **Bootstrap Aggregating (Bagging):** Cada árbol se entrena con una muestra aleatoria del mismo tamaño n , tomada con reemplazo del dataset original.
2. **Submuestreo de Características:** En cada división de cada nodo, el árbol solo puede elegir entre un subconjunto aleatorio de variables (típicamente $\sqrt{p}$ o $p/3$).

Demostración estadística: Si promediamos B estimadores independientes, cada uno con varianza σ^2 , la varianza del promedio es $\frac{\sigma^2}{B}$. ¡Random Forest reduce drásticamente la varianza del error sin aumentar el sesgo!

7.5 Pipeline Maestro de Scikit-Learn (Sin Data Leakage)

```

1  # =====
2  # PIPELINE MAESTRO DE MACHINE LEARNING EN INGENIERIA QUIMICA
3  # =====
4  import numpy as np
5  import pandas as pd
6  from sklearn.model_selection import train_test_split
7  from sklearn.preprocessing import StandardScaler
8  from sklearn.pipeline import Pipeline
9  from sklearn.linear_model import LinearRegression, Ridge
10 from sklearn.ensemble import RandomForestRegressor
11 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
12
13 # 1. Separacion de matriz de features (X) y vector objetivo (y)
14 columnas_features = ['peso_mol', 'num_C', 'num_H', 'num_O', 'nu_O2', 'ratio_C_H']
15 X = df_limpio[columnas_features]
16 y = df_limpio['dH_combustion'] # Target en kJ/mol
17
18 # 2. Particion Train/Test estratificada en reproducibilidad (80% Train, 20% Test)
19 X_train, X_test, y_train, y_test = train_test_split(
20     X, y, test_size=0.20, random_state=42
21 )
22
23 # 3. Configuracion de estimadores dentro de Pipelines para evitar fuga de datos
24 modelos = {
25     "Regresion Lineal (OLS)": Pipeline([
26         ('escalador', StandardScaler()),
27         ('regresor', LinearRegression())
28     ]),
29     "Ridge (L2 regularizado)": Pipeline([
30         ('escalador', StandardScaler()),
31         ('regresor', Ridge(alpha=10.0))
32     ]),
33 }

```



```
33     "Random Forest (200 arboles)": RandomForestRegressor(  
34         n_estimators=200, max_depth=14, random_state=42, n_jobs=-1  
35     )  
36 }  
37  
38 # 4. Entrenamiento y evaluacion comparativa  
39 resultados = []  
40 for nombre, modelo in modelos.items():  
41     modelo.fit(X_train, y_train) # Ajustar EXCLUSIVAMENTE con datos de Train  
42  
43     pred_train = modelo.predict(X_train)  
44     pred_test = modelo.predict(X_test)  
45  
46     resultados.append({  
47         "Algoritmo": nombre,  
48         "MAE Train (kJ/mol)": round(mean_absolute_error(y_train, pred_train), 2),  
49         "MAE Test (kJ/mol)": round(mean_absolute_error(y_test, pred_test), 2),  
50         "RMSE Test (kJ/mol)": round(np.sqrt(mean_squared_error(y_test, pred_test)),  
51         2),  
52         "R2 Test": round(r2_score(y_test, pred_test), 4)  
53     })  
54 df_eval = pd.DataFrame(resultados)  
55 print(df_eval.to_string(index=False))
```

CAPÍTULO 8

Validación Científica, Métricas y Diagnóstico de Residuales

Karol Paola, en ciencia no basta con decir que un modelo es bueno; debemos demostrar rigurosamente su precisión, sus límites de validez y sus posibles sesgos.

8.1 Fórmulas Matemáticas de las Métricas de Error

1. Error Absoluto Medio (MAE - La Métrica Reina):

$$\text{MAE} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} |y_i - \hat{y}_i| \quad (8.1)$$

Mide el error promedio en las unidades físicas reales del fenómeno (kJ/mol). Un MAE de 280 kJ/mol indica que, en promedio, la predicción del modelo se desvía en ± 280 kJ/mol del valor calorimétrico experimental.

2. Raíz del Error Cuadrático Medio (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (y_i - \hat{y}_i)^2} \quad (8.2)$$

Al elevar las diferencias al cuadrado antes de promediar, el RMSE penaliza severamente los errores grandes o atípicos (*outliers*). Si el RMSE es significativamente mayor que el MAE, significa que el modelo comete fallos extremos en un subgrupo de moléculas.

3. Coeficiente de Determinación (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^{n_{\text{test}}} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n_{\text{test}}} (y_i - \bar{y})^2} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (8.3)$$

Representa la fracción de la varianza del target explicada por el modelo predictivo.

¡Cuidado con el Espejismo del R^2 en Termoquímica!

Como la entalpía de combustión de compuestos orgánicos abarca un rango enorme (desde -890 kJ/mol para el metano hasta más de -15000 kJ/mol para alcanos pesados), el denominador de la varianza total (SS_{tot}) es colosal. Un modelo deficiente que se equivoque por ± 400 kJ/mol en cada predicción puede arrojar tranquilamente un $R^2 = 0.975$. **Tu criterio de calidad en laboratorio debe ser siempre el MAE.**

8.2 El Diagnóstico Gráfico de Residuales ($e_i = y_i - \hat{y}_i$)

Grafica siempre los residuales frente a las entalpías predichas:

```
1 import matplotlib.pyplot as plt
2
3 y_pred = modelos["Random Forest (200 arboles)"].predict(X_test)
4 residuales = y_test - y_pred
5
6 plt.figure(figsize=(7.5, 4.8))
7 plt.scatter(y_pred, residuales, alpha=0.5, color='navy', edgecolors='k', s=35)
8 plt.axhline(0, color='red', linestyle='--', linewidth=1.5)
9 plt.title('Diagnostico de Residuales: Random Forest Regressor', fontsize=12)
10 plt.xlabel('$\Delta H_c^{\circ}$ Predicho (kJ/mol)')
11 plt.ylabel('Residual ($y_{\mathrm{exp}} - y_{\mathrm{pred}}$) [kJ/mol]')
12 plt.grid(True, linestyle=':', alpha=0.6)
13 plt.tight_layout()
14 plt.show()
```

Cómo interpretar la gráfica de residuales como una profesional:

- **Banda aleatoria horizontal (Homocedasticidad):** La nube de puntos se distribuye simétricamente alrededor de la línea cero sin ensancharse. *El modelo es robusto e insesgado.*
- **Forma de embudo (Funnel shape / Heterocedasticidad):** La nube es estrecha a entalpías pequeñas y se ensancha a entalpías muy negativas. *Indica que la incertidumbre crece en moléculas grandes.*
- **Puntos solitarios muy alejados ($|e_i| > 1500$ kJ/mol):** Son anomalías que requieren inspección química (¿SMILES mal escrito?, ¿error tipográfico en el CSV original?).

CAPÍTULO 9

Plan de Trabajo: Metas del Viernes y Hoja de Ruta a Diciembre

Karol Paola, este capítulo define con exactitud qué debes alcanzar al concluir tu primera semana de trabajo y cómo se estructura el camino cronológico hasta el hito del 10 de diciembre de 2026.

9.1 Checklist Obligatoria para este Primer Viernes

Antes de cerrar tu sesión de trabajo de este viernes, debes verificar el cumplimiento estricto de cada uno de los siguientes puntos:

Checklist Operativa del Primer Viernes

- ☐ **Entorno PyCharm Funcional:** El entorno virtual `.venv` está configurado y el intérprete ejecuta Python 3.10+ sin errores de importación.
- ☐ **Estructura Limpia de Carpetas:** El archivo `base_entalpías.csv` está colocado en `data/raw/` y no disperso en el escritorio o en carpetas temporales.
- ☐ **Cuaderno Inicial Creado:** El archivo interactivo `notebooks/01_exploracion_inicial.ipynb` está conectado al kernel de `.venv` y carga la base de datos con rutas relativas (`os.path.join`).
- ☐ **Auditoría de Datos Realizada:** Se han ejecutado `df.info()` y `df.describe()`, identificando el número total de filas, la columna target (`dH_combustion`) y confirmando que las unidades son kJ/mol.
- ☐ **Detección de Nulos y Duplicados:** Se han cuantificado los valores nulos con `df.isnull().sum()` y los duplicados con `df.duplicated(subset=['SMILES']).sum()`.
- ☐ **ChemPy Operativo:** Se ha probado en un script el balanceo estequiométrico automático de la combustión del metano y etanol con `chempy.chemistry.balance_stoichiometry`.
- ☐ **Git y GitHub Sincronizados:** El archivo `.gitignore` excluye correctamente `.venv/`, se ha realizado el commit descriptivo de la semana y el comando `git push origin main` ejecutó limpiamente.

Fase	Periodo	Actividad Central	Entregable Oficial de Cierre
F0-ENV	Sep 04 – Sep 05	Setup de entorno, ChemPy y Git.	F0-ENV_ACT01_CFG_entorno_pycharm_v1.0_FINAL.txt F0-ENV_ACT02_SCR_funciones_chempy_v1.0_FINAL.py
F1-DAT	Sep 05 – Sep 12	Curaduría de datos, unidades y nulos.	F1-DAT_ACT03_DAT_dataset_curado_v1.0_FINAL.csv
F2-EDA	Sep 12 – Sep 26	Detección de outliers (IQR) y cálculo de descriptores moleculares.	F2-EDA_ACT04_NBK_exploracion_distribuciones_v1.0_FINAL.txt F2-EDA_ACT05_SCR_calculo_descriptores_moleculares_v1.0_FINAL.py
F3-MLB	Sep 26 – Oct 10	Modelos lineales (OLS, Ridge) y ajuste de Random Forest Regressor.	F3-MLB_ACT06_NBK_modelos_lineales_baseline_v1.0_FINAL.txt F3-MLB_ACT07_SCR_random_forest_regressor_v1.0_FINAL.py
F4-VAL	Oct 10 – Oct 17	Validación cruzada 10-fold y análisis gráfico de residuales.	F4-VAL_ACT08_NBK_diagnostico_residuales_v1.0_FINAL.txt
F5-REP	Oct 17 – Oct 31	Benchmarking y comparación de métricas contra literatura.	F5-REP_ACT09_REP_informe_benchmarking_literatura_v1.0_FINAL.pdf
F6-SIM	Oct 31 – Nov 14	Simulación termodinámica de combustión en DWSIM.	F6-SIM_SIM01_SIM_reactor_combustion_dwsim_v1.0_FINAL.txt
F7-EQK	Nov 14 – Dic 10	Puente al equilibrio químico (ΔG° , K_{eq}) y entrega final.	F7-EQK_ACT10_SCR_calculador_gibbs_keq_v1.0_FINAL.py F7-EQK_DOC01_REP_manuscrito_final_propuesta_v1.0_FINAL.pdf

Tabla 9.1: Cronograma integral del proyecto hacia el 10 de diciembre de 2026.

9.2 Hoja de Ruta Maestra por Fases (Septiembre a Diciembre 2026)

9.3 El Hito Decisivo del 10 de Diciembre de 2026

¿Por qué todo este esfuerzo de otoño tiene como horizonte el 10 de diciembre de 2026? Porque el modelado de **Equilibrio Químico** en sistemas complejos multicomponente (reacciones simultáneas, balance de energía libre de Gibbs, coeficientes de actividad no ideales y cálculo de constantes K_{eq}) requiere que domines con total naturalidad el manejo de datos moleculares, el cálculo estequiométrico automatizado y los pipelines de regresión. Las entalpías de combustión son tu plataforma de despegue; el equilibrio químico será tu consagración como investigadora autónoma.

CAPÍTULO 10

Catálogo de Errores Frecuentes y Cómo Resolverlos

Aprender a programar en ciencia de datos es, en gran medida, aprender a diagnosticar y corregir errores sin frustrarse. A continuación se presentan los problemas más comunes y su solución directa:

1. **FileNotFoundError al cargar el CSV:** *Causa:* El script se ejecuta desde una carpeta distinta a la que esperabas o utilizaste una ruta absoluta. *Solución:* Verifica tu directorio de trabajo actual con `os.getcwd()` y construye la ruta relativa con `os.path.join("../", "data", "raw", "base_entalpías.csv")`.
2. **ModuleNotFoundError: No module named 'chempy':** *Causa:* Instalaste la librería en el Python global del sistema y no en el entorno virtual `.venv` del proyecto. *Solución:* Abre la terminal en PyCharm, verifica que comience con `(.venv)` y corre `pip install chempy`.
3. **Fuga de Datos (*Data Leakage*):** *Causa:* Aplicar `StandardScaler().fit()` sobre todo el dataset antes de hacer `train_test_split`. *Solución:* Emplea siempre un objeto `Pipeline([('scaler', StandardScaler()), ('model', Ridge())])`. El pipeline ajusta el escalador únicamente sobre el Train Set.
4. **Inconsistencia de Unidades Termodinámicas:** *Causa:* Combinar columnas reportadas en kcal/mol con datos en kJ/mol. *Solución:* Aplica el factor de conversión estricto ($1 \text{ kcal} = 4.184 \text{ kJ}$) al momento de cargar el dataset crudo.
5. **Sobreajuste Severo en Random Forest (*Overfitting*):** *Causa:* Dejar `max_depth=None`, permitiendo que cada árbol crezca hasta que cada hoja tenga una sola molécula (memorización pura). *Solución:* Acota la profundidad fijando `max_depth=12` o `max_depth=14` y aumenta `min_samples_split=5`.
6. **Subir el Entorno Virtual a GitHub:** *Causa:* Olvidar agregar `.venv/` al archivo `.gitignore`. *Solución:* Añade `.venv/` en una línea de `.gitignore` y ejecuta `git rm -r -cached .venv` para desrastrearlo sin borrarlo de tu disco.
7. **Resultados no reproducibles entre corridas:** *Causa:* No fijar la semilla aleatoria en los algoritmos estocásticos. *Solución:* Especifica siempre `random_state=42` tanto en `train_test_split` como en `RandomForestRegressor`.